

熊凌峰

(+86) 13997594353 · xlf26@mails.tsinghua.edu.cn
dawnfz-lenfeng.github.io

🎓 教育背景

清华大学	直博	统计学	2026.9 - 2031.6
中国人民大学	本科	数据科学与大数据技术	2022.9 - 2026.6

</> 实习经历

阿里云（北京）科技有限公司	MaxFrame 计算引擎研发实习生	2026.1 - 现在
设计 CPU/GPU 异构流水线加速方案，通过异步预取与在线吞吐感知优化多模态数据处理效率		
- 自研通用异构流水线引擎：将 CPU/GPU 异构任务抽象为多级流水线，基于 PyTorch 多进程与锁页内存 (pin_memory) 实现异步预取，消除 CPU→GPU 拷贝阻塞 - 设计流水线调度与动态背压：根据各 worker 队列积压动态调节 CPU 预处理与 GPU 推理速率，缓解异构设备间的速度失配 - 实现在线吞吐感知的动态批处理：实时统计推理吞吐并在线调整批次大小，在高负载下平衡吞吐与延迟，在语音转写、文档向量化等 Benchmark 场景下整体端到端耗时较 Daft 快约 11%		

🔍 科研经历

Xinference: Making Large Model Serving Easy	
aclanthology/2024.emnlp	第二作者 · EMNLP 2024 · 2024.4 - 2024.10
开发高效的大模型部署管理框架，提供 OpenAI 兼容 API 和完整的模型生命周期管理	
- 负责 Benchmark 测试：进行 Xinference 与主流分布式推理引擎 (Ray、BentoML)，以及不同推理后端 (vLLM、SGLang、llama.cpp) 延迟和吞吐量对比 - 了解主流推理框架优化技术：深入研究 PagedAttention、Continuous Batching、FlashAttention 等核心技术，了解 vLLM 的 PagedAttention 内存管理机制 - 参与类 Actor 框架的分布式优化：基于 Xoscar 分布式框架改进数据并行和张量并行策略，通过动态负载均衡和通信优化，优化大模型分布式推理资源利用率	

LLM-Driven Online Aggregation for Big Unstructured Data Analytics	
10.1007/978-981-92-0366-6_35	第二作者 · DASFAA 2026 · 2025.1 - 2025.12
设计基于 LLM 的在线聚合框架，通过动态信息抽取和自适应采样优化非结构化数据分析性能	
- 设计基于 embedding 的语义分层结构：通过 embedding 空间的层次化分组进行语义抽样，有效降低估计方差并提高查询效率 - 实现在线动态聚合框架：通过流式批量抽样和自适应方差调整，提升查询效率并保证结果质量	

🐱 项目经历

Xorbits	xorbitsai/xorbits	2024.6 - 2024.12
Xorbits 基于自研分布式框架 Xoscar，实现 numpy/pandas/sklearn 等库的分布式计算能力		
- 完成部分 API 并行计算实现：基于 MapReduce 模型重构 np.where 等操作函数，支持数据分片和分布式执行，实现与原生 NumPy 接口的完全兼容 - 了解计算图优化和算子融合等技术：了解算子融合、惰性求值、常量折叠、公共子表达式消除等优化策略，通过将多个细粒度算子合并为复合算子减少网络通信开销和中间结果存储		

⚙️ 个人技能

编程语言	Python（熟练）、C/C++、CUDA、Rust（了解）
------	--------------------------------